

elyza/ELYZA-japanese-Llama-2-7b

like 96

Follow ELYZA.inc 247



Text Generation



Transformers



PyTorch



Japanese



English

llama



text-generation-inference



arxiv:2307.09288



License: llama2



Train

Deploy

Use this model



Model card

Files

xet



Community 4

Downloads last month

1,816



Inference Providers

Text Generation

This model isn't deployed by any Inference Provider.



Ask for provider support

Model tree for elyza/ELYZA-japanese-Llama-2-7b

Adapters

2 models

Merges

4 models

Quantizations

1 model

Spaces using elyza/ELYZA-japanese-Llama-2-7b 28

Collection including elyza/ELYZA-japanese-Llama-2-7b

ELYZA-japanese-Llama-2-7b Collection

7b Llama-2 models augmented for Japan... • 6 items • Updated Aug 14, 2024 • 5

ELYZA-japanese-Llama-2-7b



ELYZA- japanese- Llama-2-7b

🔗 Model Description

ELYZA-japanese-Llama-2-7b は、Llama2をベースとして日本語能力を拡張するために追加事前学習を行ったモデルです。詳細は [Blog記事](#) を参照してください。

🔗 Usage

```
import torch
from transformers import AutoModelForCausalLM, AutoTokenizer

B_INST, E_INST = "[INST]", "[/INST]"
B_SYS, E_SYS = "<<SYS>>\n", "\n<</SYS>>\n\n"
DEFAULT_SYSTEM_PROMPT = "あなたは誠実で優秀な日本人のアシスタントです。"
text = "クマが海辺に行ってアザラシと友達になり、最終的には家に帰るというプロットの短編小説を書い"

model_name = "elyza/ELYZA-japanese-Llama-2-7b-instruct"
tokenizer = AutoTokenizer.from_pretrained(model_name)
model = AutoModelForCausalLM.from_pretrained(model_name, torch_dtype="auto")

if torch.cuda.is_available():
    model = model.to("cuda")
```

```

prompt = "{bos_token}{b_inst} {system}{prompt} {e_inst} ".format(
    bos_token=tokenizer.bos_token,
    b_inst=B_INST,
    system=f"{B_SYS}{DEFAULT_SYSTEM_PROMPT}{E_SYS}",
    prompt=text,
    e_inst=E_INST,
)

with torch.no_grad():
    token_ids = tokenizer.encode(prompt, add_special_tokens=False, return_tensors=

    output_ids = model.generate(
        token_ids.to(model.device),
        max_new_tokens=256,
        pad_token_id=tokenizer.pad_token_id,
        eos_token_id=tokenizer.eos_token_id,
    )
output = tokenizer.decode(output_ids.tolist()[0][token_ids.size(1) :], skip_special_tokens=True)
print(output)
"""
承知しました。以下にクマが海辺に行ってアザラシと友達になり、最終的には家に帰るというプロットの短編

クマは山の中でゆっくりと眠っていた。
その眠りに落ちたクマは、夢の中で海辺を歩いていた。
そこにはアザラシがいた。
クマはアザラシに話しかける。

「おはよう」とクマが言うと、アザラシは驚いたように顔を上げた。
「あ、こんにちは」アザラシは答えた。
クマはアザラシと友達になりたいと思う。

「私はクマと申します。」クマは...
"""

```

[🔗](#) ELYZA-japanese-Llama-2-7b Models

Model Name	Vocab Size	#Params
elyza/ELYZA-japanese-Llama-2-7b	32000	6.27B
elyza/ELYZA-japanese-Llama-2-7b-instruct	32000	6.27B
elyza/ELYZA-japanese-Llama-2-7b-fast	45043	6.37B
elyza/ELYZA-japanese-Llama-2-7b-fast-instruct	45043	6.37B

[🔗](#) Developers

以下アルファベット順

- [Akira Sasaki](#)
- [Masato Hirakawa](#)
- [Shintaro Horie](#)
- [Tomoaki Nakamura](#)

[🔗](#) Licence

Llama 2 is licensed under the LLAMA 2 Community License, Copyright (c) Meta Platforms, Inc. All Rights Reserved.

[🔗](#) How to Cite

```
@misc{elyzallama2023,  
  title={ELYZA-japanese-Llama-2-7b},  
  url={https://huggingface.co/elyza/ELYZA-japanese-Llama-2-7b},  
  author={Akira Sasaki and Masato Hirakawa and Shintaro Horie and Tomoaki Nakamura},  
  year={2023},  
}
```

[🔗](#) Citations

```
@misc{touvron2023llama,  
  title={Llama 2: Open Foundation and Fine-Tuned Chat Models},  
  author={Hugo Touvron and Louis Martin and Kevin Stone and Peter Albert and A  
  year={2023},  
  eprint={2307.09288},  
  archivePrefix={arXiv},  
  primaryClass={cs.CL}  
}
```